Modélisation Transactionnelle des Systèmes sur Puce avec SystemC Ensimag 3A — filière SEOC Grenoble-INP

Notions Avancé en SystemC/TLM

Frédéric Pétrot

frederic.petrot@univ-grenoble-alpes.fr

2019-2020





```
Introduction : systèmes sur puce et modélisation au niveau transactionnel
09/10 (FP) Introduction au C++
15/10 (FP) Modélisation TLM en SystemC
16/10 (FP) Présentation de SystemC, éléments de base
22/10 (FP) Communications haut-niveau en SystemC
23/10 (FP) Intervenant extérieur : Laurent Maillet-Contoz (STMicroelectronics)
05/11 (FP) TP1 (1/1): Première plateforme SystemC/TLM
12/11 (FP) Utilisations des plateformes TLM
13/11 (FP) TP2 (1/3): Intégration du logiciel embarqué
26/11 (FP) TP2 (2/3): Intégration du logiciel embarqué
27/11 (FP) TP2 (3/3): Intégration du logiciel embarqué
03/12 (OM) Synthèse d'architecture
04/12 (OM) TP3 (1/2): Synthèse de haut niveau et génération de circuits numériques
11/12 (OM) TP3 (2/2): Synthèse de haut niveau et génération de circuits numériques
17/12 (FP) Notions Avancées en SystemC/TLM
18/12 (FP) Perspectives et conclusion
```

Sommaire

- Bug, or not Bug?
- Optimisations de Performances
- Questions de Sémantique
- 4 Power and Temperature Estimation



Sommaire

- Bug, or not Bug?
- Optimisations de Performances
- Questions de Sémantique
- 4 Power and Temperature Estimation



What is a bug?

- Launch a SystemC/TLM simulation
- It produces incorrect result

Question



Good news or bad news?



A Few Kinds of Model/Simulator's Bugs

- Hardware bug:
 - Simulator design bug, corresponding to a real hardware bug
 - Simulator programming error, irrelevant in real hardware
- Software bug: software doesn't run properly on simulator
 - Because software is buggy?
 - Because simulator is not faithful?



A Few Kinds of Model/Simulator's Bugs

- Hardware bug:
 - 🚺 Simulator design bug, corresponding to a real hardware bug 🥯
 - 2 Simulator programming error, irrelevant in real hardware
- Software bug: software doesn't run properly on simulator
 - Because software is buggy?
 - Because simulator is not faithful?



Model only.
Will be thrown away
in final product

el/Simulator's Bugs

- Hardware bug/
 - Simulator design bug, corresponding to a real hardware bug
 - Simulator programming error, irrelevant in real hardware
- Software bug: software doesn't run properly on simulator
 - Because software is buggy?
 - 2 Because imulator is not faithful?

Actual Software.
Will be embedded in final product



What Can we Expect from the Model?

Software runs on TLM ⇒ Software runs on real chip



What Can we Expect from the Model?

Software runs on TLM ⇒ Software runs on real chip



Software doesn't run on real chip

⇒ Software doesn't run on TLM



Another Kind of "Bug"

- Up to now:
 - Hardware Model doesn't work
 - Software doesn't run on hardware model
- What about:
 - ▶ Software does run on hardware model, but not on real chip



Another Kind of "Bug"

- Up to now:
 - Hardware Model doesn't work
 - Software doesn't run on hardware model
- What about:
 - Software does run on hardware model, but not on real chip

Hiding bugs \neq Fixing bugs



Sets of Behaviors, Faithfulness

- An ideal TLM model ...
 - Should exhibit all behaviors of the real system
 - May exhibit more behaviors than the real system
 - Should not exhibit "too many" unrealistic behaviors



TLM should exhibit all behaviors of the real system (1/2)

Software CPU1

```
compute_img(&buf);
img_computed = 1;
```

Software CPU2

```
while (img_computed != 1)
  continue;
read_img(&buf);
```

Question



Are all interleavings correct?



TLM should exhibit all behaviors of the real system (2/2)

(Incorrect) Software CPU1

```
img_computed = 1;
compute_img(&buf);
```

Software CPU2

```
while (img_computed != 1)
  continue;
read_img(&buf);
```

Question



Are all interleavings correct?



TLM should exhibit all behaviors of the real system (2/2)

(Incorrect) Software CPU1

```
img_computed = 1;
compute_img(&buf);
```

Software CPU2

```
while (img_computed != 1)
  continue;
read_img(&buf);
```

Question



Are all interleavings correct?

Question



Will we see the bug in a simulation?

renoble INP

TLM may exhibit more behaviors than the real system

Software CPU1

```
compute_img(&buf);
imq computed = 1;
```

Software CPU2

```
count=0;
while (img computed != 1)
  count++;
assert (count == 3);
read_img(&buf);
```



TLM should not exhibit "too many" unrealistic behaviors

Software CPU1

```
dest = stq fast();
```

Software CPU2

```
stg_very_slow();
do stq with (dest);
```

- No explicit synchronization between dest = ... and access to dest ...
- ... but do we want to see this bug?



Set of Behaviors and Non-Determinism

- TLM models should exhibit several behaviors
- Several possibilities ⇒ non-determinism
- Implementing non-determinism:
 - Formal verification approach: exhaustive exploration
 - Simulation approach: random



An Example of Non-Determinism: Loose Timing

```
// generates a pseudo-random float
// between 0.0 and 0.999...
float randfloat()
    return rand()/(float(RAND MAX)+1);
// loose timing
void pv wait (x) {
    wait (x*(randfloat()+0.5));
```

Question



What does it do?



Sommaire

- Bug, or not Bug?
- Optimisations de Performances
- Questions de Sémantique
- 4 Power and Temperature Estimation



Sommaire de cette section

- 2
- Optimisations de Performances
- Transaction bloc
- Timing « approximé » et temporal decoupling
- Parallélisation de SystemC



Transaction bloc

Avant

Après

```
// 1 echange atomique
block_write(socket, ad, data, size);
```

- Grosse granularité
- Beaucoup plus rapide en simulation



Transaction bloc

Avant

```
for (ensitlm::addr t ad = ad0;
     ad < ad0+size; ad++) {
   write(socket, ad,
          data[ad]);
```

Après

```
// 1 echange atomique
block_write(socket, ad, data, size);
```

- Grosse granularité
- Beaucoup plus rapide en simulation

Question



Perd-t-on en fidélité?



Sommaire de cette section

- Optimisations de PerformancesTransaction bloc
 - Timing « approximé » et temporal decoupling
 - Parallélisation de SystemC



2019-2020

- Constat : les changements de contexte des threads sont lents 1
- Conséquence 1 : wait coûte cher!
- Conséquence 2 : on évite de mettre des wait.



^{1.} Malgré l'utilisation des quick threads ou des pthreads

Problème :

- En PVT, granularité de temps fine.
- ightharpoonup \Rightarrow 1 wait pour chaque avancement du temps.
- \Rightarrow simulation lente.



Problème :

- En PVT, granularité de temps fine.
- ightharpoonup \Rightarrow 1 wait pour chaque avancement du temps.
- ▶ ⇒ simulation lente.

Solution proposée en TLM 2:

- Chaque processus peut être « en avance » sur le temps global.
- (L'avance correspond à l'argument sc_time des méthodes transport de TLM-2, ignoré dans ENSITLM)
- Quand faire les wait () (i.e. laisser le reste de la plate-forme rattraper notre avance)?
 - * Quantum Keeping: Si on est plus « en avance » que le quantum (constante de temps choisie par l'utilisateur)
 - ★ Synchronisation explicite: Avant (ou après?) les points de synchronisation



Exemple

```
sc_time t = SC_ZERO_TIME; // local advance over SystemC time
local_computation(); // Instantaneous wrt SystemC
t += sc_time(12, SC_NS); // don't wait() now
other_computation();
t += sc_time(3, SC_NS);
socket.write(addr, data, t); // may update t
wait(t); t = SC_ZERO_TIME; // Catch-up with SystemC time
send_interrupt();
```



Exemple

```
sc_time t = SC_ZERO_TIME; // local advance over SystemC time
local_computation(); // Instantaneous wrt SystemC
t += sc_time(12, SC_NS); // don't wait() now
other_computation();
t += sc_time(3, SC_NS);
socket.write(addr, data, t); // may update t
wait(t); t = SC_ZERO_TIME; // Catch-up with SystemC time
send_interrupt();
```

Question



Quels sont les problèmes?



Sommaire de cette section

- Optimisations de Performances
 - Transaction bloc
 - Timing « approximé » et temporal decoupling
 - Parallélisation de SystemC



Paradoxe:

- Les systèmes sur puces sont parallèles
- SystemC a une notion de processus
- SystemC n'exploite qu'un processeur!



- Paradoxe:
 - Les systèmes sur puces sont parallèles
 - SystemC a une notion de processus
 - SystemC n'exploite qu'un processeur!
- Solution (très) naive:
 - ▶ 1 SC THREAD → 1 pthread
 - On lance tout en parallèle.
 - → beaucoup de pthreads, ne passe pas à l'échelle.



- Paradoxe:
 - Les systèmes sur puces sont parallèles
 - SystemC a une notion de processus
 - SystemC n'exploite qu'un processeur!
- Solution (très) naive:
 - ▶ 1 SC THREAD → 1 pthread
 - On lance tout en parallèle.
 - ▶ ⇒ beaucoup de pthreads, ne passe pas à l'échelle.
- Solution moins naive:
 - ▶ *N* processeurs $\rightarrow \approx N$ pthreads.
 - ▶ Gestion du mapping « processus SystemC » ↔ pthread dans le kernel SystemC.



- Paradoxe:
 - Les systèmes sur puces sont parallèles
 - SystemC a une notion de processus
 - SystemC n'exploite qu'un processeur!
- Solution (très) naive:
 - ▶ 1 SC THREAD → 1 pthread
 - ► On lance tout en parallèle.
 - ▶ ⇒ beaucoup de pthreads, ne passe pas à l'échelle.
- Solution moins naive:
 - ▶ *N* processeurs $\rightarrow \approx N$ pthreads.
 - ▶ Gestion du mapping « processus SystemC » ↔ pthread dans le kernel SystemC.

Question



Où est le problème?



- Si on veut faire les choses proprement:
 - Analyse statique des dépendances de données
 - Prise en compte à l'exécution
 - ▶ (e.g. DRT de Yussef Bouzouzou, 2007—2 ans de travail)
 - ▶ ⇒ on sort du principe « SystemC, c'est facile à compiler, g++ le fait très bien ».
- Problème restant:
 - Parallélisation « à l'intérieur du δ -cycle », mais exécuter en parallèle des processus censés s'exécuter à différents instants de simu = difficile.
- Solutions envisageables:
 - Profiter du découplage temporel pour paralléliser
 - ► Tâches avec durée (cf. jTLM, et maintenant sc during)



Parallélisation de SystemC : conclusion

- C'est dur.
 PDES (Parallel Discrete Event Simulation)
 théorie établie entre 1979 (Chandy-Misra, Lamport) et 1990 (Fujimoto)
 implantations peu efficaces pour nos problèmes
- La plupart des gens qui le font ne se soucient pas de préservation de la sémantique
- Solution en pratique : lancer N simulations sur N machines!
- Il faut peut-être un autre langage?



Accélération des simulations SystemC

- Code interne aux composants = C++
 - \Rightarrow g++ -03 et le tour est joué (ou pas)
- Changement de context = cher :
 - Ordonnancement
 - Sauvegarde/restauration de tous les registres
 - ► Changement du pointeur de pile ⇒ cache-miss
 - ► Changement du compteur programme ⇒ vidage de pipeline
 - sans compter les flushs de TLB, etc, suivant la manière dont les threads sont implantés
- Transactions = cher :
 - ► Plusieurs appels de méthodes virtuelles (⇒ non inline-ables)
 - ▶ Décodage d'adresse pour router la transaction (en O(nb slave))
 - ► ⇒ Là où la vraie plateforme fait un load/store, le code TLM exécute du code difficile à optimiser.



Accélération des simulations SystemC Minimiser le coût dû au changement de contexte

- Utilisation de SC_METHOD à la place des SC_THREAD (pas toujours possible)
- Minimisation du nombre de wait à exécuter
- Ordonnancement statique (http://www.cprover.org/scoot/: plus de travail à la compilation, simulation 2 à 6 fois plus rapide sur des exemples)



 DMI = Direct Memory Interface: on récupère un pointeur sur la zone mémoire intéressante, et on fait des accès sans passer par le bus.



Accélération des simulations SystemC Minimiser le coût du aux transactions

• DMI = Direct Memory Interface: on récupère un pointeur sur la zone mémoire intéressante, et on fait des accès sans passer par le bus.

Question



Quel est le problème?



 DMI = Direct Memory Interface: on récupère un pointeur sur la zone mémoire intéressante, et on fait des accès sans passer par le bus.

Question



Quel est le problème?

Techniques de compilation spécifiques : lancer une passe d'optimisations après l'élaboration (prototype basé sur LLVM développé au LIAMA et à Verimag)



- Optimisations de Performances
- Questions de Sémantique
- Power and Temperature Estimation



Sommaire de cette section

- Questions de Sémantique
 - Comparaison TLM/RTL
 - Verification Formelle





Quel est le problème?



Sommaire de cette section

- Questions de Sémantique
 - Comparaison TLM/RTL
 - Verification Formelle



Vérification Formelle de SystemC

- Plusieurs approches :
 - Compilation de SystemC vers des langages sources des outils de preuve
 - ★ Front-end SystemC dédié
 - Modélisation formelle de toutes les constructions SystemC
 - Exploration exhaustive de l'espace d'états à l'exécution
 - ★ stateless: on explore tous les ordonnancements de taille < N</p>
 - ★ statefull: on ajoute la possibilité de mémoriser et de comparer des états (⇒ construction de l'espace d'états entier)
 - ► En général, problème de passage à l'échelle (scalability) produits d'automates ⇒ explosion de l'espace d'états (state explosion)



Sommaire

- Optimisations de Performances
- Power and Temperature Estimation



Power and Temperature Estimation

Question



How?




Power estimation in TLM: Power-state Model



```
// SystemC thread
void compute() {
    while (true) {
        f();
        wait (10, SC MS);
        wait(irq);
```



Power estimation in TLM: Power-state Model




```
// SystemC thread
void compute() {
    while (true) {
        set_state("run");
        f();
        wait(10, SC_MS);
        set_state("idle");
        wait(irq);
    }
}
```

- Consumption depends on:
 - Activity state (switching activity inside component)
 - ► Electrical state (voltage, frequency)
 - Traffic (stimulation by other components)

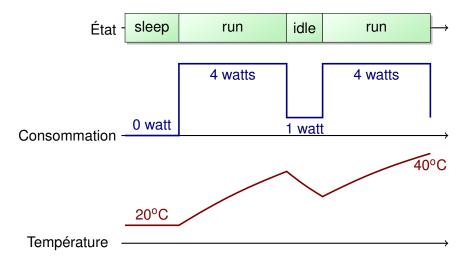


Des états à la consommation






De la consommation à la température






Puissance consommée, température, et dissipation de chaleur






Puissance consommée, température, et dissipation de chaleur



→ système d'équation différentielles, résolus par des solveurs dédiés



SystemC and Temperature Solver Cosimulation



Functionality can depend on non-functional data (e.g. validate power-management policy)



